DataMind Agent

多模态数据驱动的可解释精准问数问答智能体 · 设计报告

项目核心亮点预览页（官方要求：封面/目录后第 1–2 页）

一句话定位：把「问一句、答一句」做成「答案 + 可回放证据链路 + 明确的不知道」——系统不直接生成结论，而是先生成带类型的证据图（数据行 / 文档块 / 测量 / 规范条款为节点，实体同一性、版本适用、单位等价、时间口径、数值支持、数值冲突为边），在受控修复上限内消解冲突；无法消解时同时展示双方证据并标记待裁决，绝不自动单选来源。

亮点 1｜可解释性：答案即证据链

每条答案携带：生成的 SQL 与绑定参数、引用的文档片段、原文定位（页码/区域/句柄）、运行事件流与回放。

证据入口：GET /v1/runs/{id}、/v1/runs/{id}/evidence、/v1/runs/{id}/events；前端引用卡片与定位徽标（web/app.js）。

旋转页与非页面定位只显示标签、绝不猜测绘制（web/app.js citationRegionFrame 分支，有契约守护测试）。

来源：docs/OFFICIAL_REQUIREMENTS_MAPPING.md A4/E3/F3；PROGRESS.md「引用消费定位 / 前端消费定位」两行。

亮点 2｜受控查询：SQL Guard 把「能跑」变成「允许跑」

sqlglot AST 门禁 + 参数绑定 + 只读执行：按 AST scope 解析列权限，拒绝越权路径与不可验证的派生表。

指标口径按 business_metrics 注册表做结构比对；顶层投影必须就是批准指标，指标查询禁止 OR。

独立复查发现的 R01/R02 反例均已修复（带 CTE 同名绕过、'正确 SUM 再乘 0' 等四种篡改变体曾全部判通过）。

来源：docs/AUDIT_FIXES.md、reports/audit_fix_verification.json、PROGRESS.md 阶段流水（第 1、2 批）。

亮点 3｜多源融合：工业跨源链路已跑通并保留冲突双方

「工艺规范原文 + 只读生产 SQL」逐测量核验：单位 / 版本 / 冲突 / 超限四类判定，未登记权威时不选来源、保留双方原值。

13/13 冻结开发规则通过（合成集，不调用大模型）；来源：reports/industrial_rules.json（passed=13, case_count=13）。

通用「数据库 + 文档」跨源目前 fail-closed：datamind/agent.py 命中 cross_source 后返回 ROUTE_UNSUPPORTED，而非猜测作答。

证据图存储已在运行：evidence_nodes=1456 / evidence_edges=1359（只读 SQL 实测）；绑定列与跨源引擎为规划项。

亮点 4｜交付形态：每一次「完成」都留下可复现证据

评测与验证报告统一落在 reports/*.json，逐例保留失败样本、分母与退出码；本次交付另附 6 份真实生成物。

隔离回归在当前基线为 1297/1297（失败 0，源库未修改）；来源：reports/latest_regression.json、PROGRESS.md 当前状态表。

依赖锁定 requirements.lock 共 65 个固定版本，并有守护测试 tests/test_dependency_lock.py 校验锁与实际安装一致。

来源：docs/OFFICIAL_REQUIREMENTS_MAPPING.md D7；PROGRESS.md「仓库治理」阶段。

亮点 5｜评测纪律：拒绝、超时、上游错误单列但不移出分母

零分母一律报 N/A，不用 0 或 100% 冒充；正向与反向对照同时写（计划 §8 度量纪律）。

可机读的题面一致性护栏：data/evaluation/registry/{nl2sql,rag,robustness}_v1.json，append-only + 逐字段 diff 校

验。

实测 3/3 suite 登记与库内题面一致；来源：reports/cards/wp1a_registry.md「结果（分子分母）」表。

扫描件能力缺口如实保留：表头 5/9、字段 3/15（reports/header_initial.json、reports/document_fields.json）。

亮点 6｜诚实边界：写清楚「不能据此声称什么」

官方测试集未提供：E1/E2/E5/E6/F4/F5 的官方准确率档在本仓库内无法判定，只报自建冻结集分子/分母。

上游仅文本模型（deepseek-flash），无本地视觉权重：不主张多模态识别领先（docs/MODEL_WEIGHTS.md）。

无与公开最优方案的对比实验：不主张「业界领先」，加分材料只做机制性对照与诚实边界。

来源：docs/SCORE_GAP_LEDGER.md §5「本轮不可能完成、不要假装完成的项」。

核心亮点预览（续）与报告导读

7. 交付物一览（本次由脚本真实生成，页数实测）

文件	类型	页/幻灯片	结构检查
交付/01_设计报告_DataMind_Agent.docx + .pdf	设计报告	13 页 / 13 页	check_office.py 通过（见 §9.5）
交付/02_技术实现说明书_DataMind_Agent.docx + .pdf	技术说明书	12 页 / 12 页	check_office.py 通过
交付/03_答辩演示.pptx	答辩 PPT	20 张	check_office.py 通过 + 匿名检查
交付/04_突破与创新性自述.pdf（+ DOCX 源）	加分自述	3 页	check_office.py 通过
交付/DELIVERY_MANIFEST.json / docs/DELIVERY_CHECKLIST.md	机读清单 / 官方核对	—	JSON 可解析

8. 本报告的组织方式

按官方评分项组织，每节同时给出「已实现的证据路径」与「仍未达成的部分」，引用数字时标注来源文件（相对仓库根目录）。章节与评分项对应关系：§3 架构（E4/F13）、§4 NL2SQL（E1/E5/F4、B4/B5）、§5 RAG（E2/E6/F5、B6/B7/B9）、§6 多源融合（F1/F3）、§7 可解释性（E3/F3）、§8 中级任务与鲁棒性（E8/E9/E10/F7/F8）、§9 评测效率与交付（E7/E11/E12/F6/F10）、§10 失败样本与诚实边界。

9. 亮点预览页与生成过程的自检（可复现）

· 本报告与另一份 DOCX、一份 PPTX、一份独立 PDF 全部由仓库 .venv/bin/python + 生成脚本真实产出（脚本在 交付/_build/），非手工排版。

· 结构检查：.venv/bin/python <office-skill>/../scripts/check_office.py <file> --out reports/office_checks.json；页数用 pymupdf 读 PDF、幻灯片数用 python-pptx 读（实测值，非估算）。

· 本轮未做 PDF 逐页视觉检查（未生成渲染预览）：结构检查通过不等于版式/分页/字体渲染无问题，已计入诚实边界（§10.2）。

§3 系统架构与技术栈

3.1 分层结构

系统为 FastAPI + 原生 JavaScript 前端 + PostgreSQL 元数据库 + Qdrant 向量库四件套，全部为仓库内真实代码；架构说明见 技术文档/DataMind_Agent_技术设计说明书_V1.3.md。

层	职责	仓库路径与实测
接口层	REST + SSE；问答、运行回放、文档、上传、复核、权威、CAD、尺寸、私有 PDF	datamind/api.py（version="0.39.0"）；/openapi.json 实测 paths=75
编排层	路由（sql / rag / cross_source / 工业）、澄清、多轮 history 边界	datamind/agent.py；不传 history 时提示词与结果逐字节不变
问数层	问题帧 → Catalog/Schema 召回 → 模型 SQL → AST 门禁 → 只读执行 → 最多一次修复	datamind/sql_engine.py、catalog.py、sql_guard.py
问答层	混合检索（向量 + 词法 RRF）→ 生成 → 原文连续片段/数字校验 → 拒答	datamind/knowledge.py、rag_engine.py
解析层	统一解析契约（parse_status 五态、七类 locator、块/关系约束）+ 适配器登记	datamind/parse_contract.py；ingestion/（PDF/Office/DXF/OCR/公式）
治理层	任务预算与进程组隔离、来源权威、字段复核、可见性策略、租约	datamind/task_budget.py、authority.py、visibility.py；db/migrations/001–018

3.2 数据底座（只读实测）

对象	实测值	命令/来源
服务健康	status=ok, database=ready, knowledge=ready, worker.alive=true	curl -s http://127.0.0.1:8000/health
知识库文档	/health document_count=27；document_assets indexed=27、parsed=2	只读 SQL：select status, count(*) from document_assets group by status
切片 / 事实 / 向量	chunks=169、document_facts=23、Qdrant points_count=169	只读 SQL + GET /collections/datamind_knowledge
证据图	evidence_nodes=1456、evidence_edges=1359	只读 SQL（deploy/init/02_metadata.sql）
评测用例	evaluation_cases：nl2sql=14、rag=12、robustness=4	只读 SQL（suite 分组）
代码与迁移	git ls-files=605；db/migrations/*.sql=18（001–018）	git ls-files | wc -l；ls db/migrations

3.3 一键启动与依赖

· scripts/start_local.sh：依赖检查 → 容器 → 迁移 → 种子 → 真实摄取 → 服务；生产化启动见 scripts/start_api_background.py。

· requirements.txt + 分能力 requirements-sql/rag/ocr/formula/office/cad.txt + requirements.lock（65 个固定版本）。

· 权重不随包：docs/MODEL_WEIGHTS.md 逐项列路径/体积/SHA256/获取脚本/缺失时降级行为。

· 边界：本报告未在干净空库环境中重跑启动演练（禁止重建容器/库），故不主张「新环境已验证可启动」。

§4 NL2SQL 与受控查询（E1 / E5 / F4；B4 / B5）

4.1 链路

```
question → query_frame(实体/指标/时间/范围) → Catalog.retrieve(词法+别名+枚举+JoinGraph, Top-8)
        → 模型生成 SQL → sql_guard（AST 列权限 + 口径结构比对 + 参数绑定）
        → 只读执行 → 失败分类 → 最多一次受控修复 → answer(+sql,+rows,+evidence)
```

4.2 已有证据（分子/分母）

项	分子/分母	来源
零售套题通过	14/14（passed=14, total=14, cases=14）	reports/nl2sql.json
Schema Linking 表召回@5	31/31（rate=1.0）	reports/schema_linking.json summary
语义锚点列召回@5	28/28（rate=1.0）	同上
指标召回@5 / 连接路径正确	4/4 / 6/6（含 18 条自建题）	同上（case_count=18）
工业限定问数	8/8 开发题、模型前澄清 2/2	PROGRESS.md「工业模型问数」行
鲁棒性套题	4/4（robustness）	reports/robustness.json

4.3 仍未达成

· 无官方测试集：E5/F4 的「≥90% 得 10 分」档在本仓库内无法判定；14/14 为自建小样本、较早代码，不可外推。

· WP1 要求的新增子集（复杂 SQL ≥15、拒答 ≥6、鲁棒 ≥10）在本轮为 not_attempted，原因见 reports/cards/wp1a_registry.md。

· 库内题面标签与 gold_sql 存在不一致（nl2sql-006 标「JOIN 2 表」实为 3 表；nl2sql-009 标「退款 JOIN 3 表」实为单表），已如实登记未改写。

4.4 口径护栏

题面入仓并 append-only 冻结：data/evaluation/registry/{nl2sql,rag,robustness}_v1.json；scripts/eval_registry.py check 实测 3/3 一致（退出码 0）；篡改临时副本被检出（退出码 1）；重复冻结被拒绝（退出码 2）。来源：reports/cards/wp1a_registry.md。

§5 RAG 文档问答（E2 / E6 / F5；B6 / B7 / B9）

5.1 链路与拒答纪律

```
question → 混合检索(向量 BGE/Qdrant + 词法 RRF) → 候选片段
        → 生成（只允许使用本次候选证据）→ 原文连续片段匹配 + 数字必须出现在引用中
        → 不满足即拒答（insufficient），不补写、不猜测
```

· 文档范围必须显式：1–8 份无重复公开文件（scope.document_refs），每文件必须有相关片段否则阻断。

· 证据覆盖不完整如实报告 MULTIFILE_EVIDENCE_INCOMPLETE；0 切片文档被选中时服务端拒绝 DOCUMENT_SELECTION_NOT_SEARCHABLE（PROGRESS.md 第 2 批 2a）。

· 表格/公式等解析缺口直接进入拒答路径：公式图片无公式文本的题目按纪律拒答而不是猜（README:178）。

5.2 已有证据

项	分子/分母	来源
RAG 套题通过（历史两轮）	10/12	reports/rag.json、reports/rag_second.json
可答题目数 / 拒答	answerable_count=11、case_count=12	reports/rag.json
检索 recall@5 / MRR@10	1.0 / 0.9545454545454546	reports/rag.json
字段级端到端正确率	10/12	reports/rag_fields.json
扫描件表头 / 字段	5/9、3/15（缺口如实保留）	reports/header_initial.json、reports/document_fields.json
CAD 能力分层冻结集	31/31、365 条断言（合成集，非泛化成绩）	reports/cad_capability_v1.json

5.3 仍未达成

· 无独立逐结论忠实度三态标注（支持/矛盾/无依据）：E6 只报端到端正确率，不能当忠实度。

· 多文档固定集与多模态问答端到端集未做；上传管道 vector_index 为 deferred，审批后文档在有切片前不可问答。

· B7 混乱目录恢复、B9 清晰度评分与错别字校正无专项集；B8 文档复杂度评估在映射表中为「未实现」。

§6 多源融合与证据绑定（F1 / F3）

6.1 已实现的跨源链路（限定：工业结构）

已实现的是「一份工艺/质检原文 + 只读生产 SQL」的逐测量核验：从原文取阈值与适用范围，绑定单位与版本后查询数据库，判定超限 / 冲突 / 需复核，冲突时保留双方原值。

项	值	来源
冻结开发规则通过	13/13（passed=13, case_count=13）	reports/industrial_rules.json
冲突集合 / 超限集合	conflicts=["M001-1"]、out_of_range=["M001-1","M006-2"]	同上 runs[0].summary
是否调用模型	model_used=false（纯规则核验）	同上 runs[0].versions
证据图存储	evidence_nodes=1456 / evidence_edges=1359	只读 SQL
合成性声明	「Synthetic demonstration … no factory data, real approvals or independent accuracy claims」	同上 source_manifest.provenance

6.2 通用跨源仍 fail-closed

· datamind/agent.py 的 route_for() 仅关键词命中 cross_source，命中后直接返回 ROUTE_UNSUPPORTED（审计 §5 与 SCORE_GAP_LEDGER F1）。

· 现有 evidence_nodes/edges 没有 source_sha256/version/unit/time_scope 绑定列，也没有 entity_match/version_scope 等边类型 CHECK；「19 号证据图已建」不可主张（docs/SCORE_GAP_LEDGER.md §5）。

· 因此 F1 的「≥3 种结构不同的跨源问题」未达成；本报告只报已有工业链路的 13/13，不外推为跨源种类数。

6.3 创新点（单一贡献）

版本化的跨源证据绑定 + 可控修复：把「实体/版本/单位/口径绑定」提升为一等公民，并给出可复现度量（绑定准确率、错误绑定率、冲突检出率、误修复率）与受控修复上限。详见 交付/04_突破与创新性自述.pdf 与 §9.4 的消融表。

§7 可解释性与可追溯（E3 / F3）

能力	具体形态	仓库证据
SQL 展示	答案携带生成的 SQL 与绑定参数	datamind/api.py、web/app.js
文档引用	引用卡片显示原文片段 + 定位徽标（页码/区域/句柄）	web/app.js citationLocators
区域高亮	未旋转 PDF 页可展开原页区域高亮；旋转页只显示标签	web/app.js citationRegionFrame + 契约守护测试
运行回放	事件流与证据接口，前端按 run_id 回放	GET /v1/runs/{id}、/evidence、/events
关系呈现	引用载荷附已存契约关系（只附存储中确有的，失败不阻断）	datamind/parse_contract.py read_relations
边界	旋转页 / 非页面定位 / 无定位文档，一律不猜测绘制或推导区域	PROGRESS.md「引用消费定位」「前端消费定位」

7.1 仍未达成

· 跨源答案的证据卡片（数据行 + 文档块 + 版本 + 单位 + 冲突双方）尚无载体，因为通用跨源引擎未建。

· 关系不参与排序/打分/重排/冲突消解（PROGRESS.md「契约关系消费」行明确标注）。

· 前端为静态资源，变更后需浏览器刷新；本轮未做界面视觉验收。

§8 中级任务与鲁棒性（E8 / E9 / E10；F7 / F8）

官方难题	状态	已有证据 / 缺口
B1 要素识别与纠错标准化	部分	entity_aliases(approved) 参与 Schema 召回（catalog.py）；无通用纠错评测
B2 可扩展要素提取	部分	领域知识存于数据库注册表（中文名/别名/枚举/语义角色）；无新增领域成本实测
B3 语义校验与澄清	已实现（限定）	clarify()/NEEDS_CLARIFICATION；工业模型前澄清 2/2；无「不必要澄清率」指标
B4 Schema Linking	已实现（限定）	表 31/31、列 28/28、指标 4/4、路径 6/6（18 条自建题）
B5 多表 JOIN/聚合/嵌套	部分	sql_guard 语义门禁；样本小、无公开基准
B6 公式识别与计算	部分（仅识别）	formula worker + LaTeX 结构校验；无公式求值引擎（6b 未实现）
B7 混乱目录层级恢复	部分	标题树优先切片 + heading_level/reading_order；无专项鲁棒集
B8 文档复杂度评估	未实现	全仓库仅命中评测用例的手工 difficulty 标签
B9 文档质量检测与告警	部分	parse_status 五态、quality_findings、OCR 置信度；无清晰度评分与繁简纠错

8.1 多轮上下文（E10）

· 契约层已实现：/v1/chat 与 /v1/chat/stream 接受客户端 history（≤20 条、单条 ≤2000 字符、合计 ≤8000，超限拒绝不截断）。

· 历史以 trust="untrusted" 边界区块送入模型并附防注入声明；实测把 DROP TABLE orders 放进历史后 SQL 与参数完全不变。

· turns_used 如实返回；不传 history 时提示词与结果逐字节不变（三种独立证明，tests/test_multi_turn.py 33 项）。

· 仍未达成：「连续 5 轮以上准确」无冻结对话集评测；前端未接入 history；无服务端会话。

8.2 鲁棒性（E9 / F7）

· robustness 套题 4/4（错别字、口语简称、越权拒答、空结果各 1 条）；规模远小于计划要求的 ≥10 条。

· 权限矩阵、任务隔离、失败状态与格式兼容较完善；模糊/低质量真实输入的覆盖仍少。

· 扫描件解析失败边界如实保留为数字（表头 5/9、字段 3/15），不隐藏。

§9 评测、效率与交付清单

9.1 系统效率（E7 / F6）——已有实测，缺分析与优化对照

路径	规模点	中位耗时	峰值 RSS	状态
CAD 解析	100 / 1000 / 5000 / 20000 实体	251.1 / 283.3 / 445.2 / 897.9 ms	191.7 / 199.1 / 237.5 / 366.8 MB	后两档 partial（blocks 上限 2000）
文档选择读取	1 / 2 / 5 / 8 份	102.9 / 106.2 / 106.9 / 107.3 ms	60.7 / 61.0 / 61.4 / 61.6 MB	实际读取 9 / 14 / 34 / 44 行

来源：reports/scale_v1.json（每点 3 次；机器 Apple M5 Pro、15 核、Python 3.14.5；报告自带 4 条免责：单机单进程、无 CPU 绑定/cgroup、无并发负载、非生产吞吐承诺）。

· 仍未达成：无时间复杂度理论分析、无瓶颈定位、无优化前后对照、无并发负载、无 SQL 侧多规模（1 千/1 万/10 万行）。

· CAD 后两档为受限输出路径测量（blocks 上限 2000），不得当作完整解析 2 万实体的证明。

9.2 评测与回归口径

项	值	来源
完整隔离回归（当前权威分母）	1297/1297，失败/错误 0，源库未修改	reports/latest_regression.json、PROGRESS.md
题面一致性护栏	3/3 suite 一致；重复冻结被拒（exit 2）；篡改被检出（exit 1）	reports/cards/wp1a_registry.md
统一报告 schema 检查	0/3 既有报告符合（如实结果，非脚本缺陷）	reports/cards/wp1a_registry.md
依赖锁	requirements.lock 65 个固定版本 + 守护测试	docs/OFFICIAL_REQUIREMENTS_MAPPING.md D7

9.3 消融实验（创新举证用，合成机制替身）

臂	正确/例数	准确率	误修复率	冲突检出	未消解
ocr_text	3/16	0.1875	N/A（未改写）	0/4	0
structured	11/16	0.6875	0.0	4/4	0
local	11/16	0.6875	0.1429（2 例）	4/4	0
full	16/16	1.0	0.0	4/4	2（保留双方证据）

来源：reports/vcar_ablation.json（dataset 16 例，sha256 74cbbc1e…；报告自注「合成机制消融，不调用任何模型；不是 OCR/问答准确率」）。

9.4 交付清单（本次真实生成，页数实测）

文件	页/幻灯片（实测）	字节数	结构检查
交付/01_设计报告_DataMind_Agent.docx	13	53791	见 reports/office_checks.json
交付/01_设计报告_DataMind_Agent.pdf	13	510294	pymupdf 页数

交付/02_技术实现说明书_DataMind_Agent.docx	12	53915	见 reports/office_checks.json
交付/02_技术实现说明书_DataMind_Agent.pdf	12	569582	pymupdf 页数
交付/03_答辩演示.pptx	20 张幻灯片	73082	见 reports/office_checks.json
交付/04_突破与创新性自述.pdf	3	334019	pymupdf 页数

清单明细（含 sha256 与生成命令）见 交付/DELIVERY_MANIFEST.json；官方提交物逐项状态见 docs/DELIVERY_CHECKLIST.md。

9.5 结构检查结果

两个 DOCX 与 PPTX 均用 office 技能自带检查器验证（ZIP/XML 完整性、关系、段落/表格/幻灯片计数、必需文本断言），结果 JSON 存 reports/office_checks.json。检查结论：全部结构完整；本轮未做逐页视觉检查（无渲染预览），版式风险未消除。

§10 失败样本与诚实边界

10.1 必须留在报告里的失败样本

失败	事实	来源
RAG 2 例未通过	12 例中 10 通过：1 例上游错误、1 例缺表头/公式拒答	reports/rag.json
扫描件表头/字段	表头 5/9、字段 3/15	reports/header_initial.json、reports/document_fields.json
本地修复臂误修复	2 例误修复（misrepair_rate=0.1429，占原正确输入 0.5）	reports/vcar_ablation.json arms[local]
ocr_text 臂漏检冲突	4 个真实冲突全部漏检（recall=0.0）	reports/vcar_ablation.json arms[ocr_text]
题面标签不一致	nl2sql-006（标 2 表实为 3 表）、nl2sql-009（标 3 表实为单表）	reports/cards/wp1a_registry.md
历史报告不符合统一 schema	nl2sql.json 57 项、rag.json 49 项、robustness.json 17 项问题	reports/cards/wp1a_registry.md

10.2 诚实边界（不能据此声称什么）

1. 不得声称任何官方得分、名次或晋级概率：官方测试集未提供，本报告全部数字为自建集/合成集实测。
2. 不得声称多模态识别领先：上游仅文本模型 deepseek-flash，无本地视觉权重目录（docs/MODEL_WEIGHTS.md）。
3. 不得声称「业界领先」：无与公开最优方案的对比实验；V-CAR 为 16 例合成机制替身，只解释机制。
4. 不得声称「证据图存储已建成完整版本」：现只有基础表（1456/1359 行），缺绑定列与边类型 CHECK。
5. 不得把 CAD 31/31 当作泛化或工厂材料成绩：报告自注 is_independent_factory_data=false、is_blind_test=false。
6. 不得把历史 14/14、10/12 当作 0.39.0 的成绩：来自较早代码与小样本（审计 §4）。
7. 不得声称干净环境已验证可启动：本轮禁止重建容器/库，未做空库演练。
8. 本轮未做 PDF 视觉检查：结构检查通过不代表版式、分页或字体渲染无问题。

10.3 评分联动与当前判断

官方项	本报告能提供什么	当前判断
E11 技术文档（10）	Word + PDF 成套、按评分项组织、含图表与失败说明	提交形态已具备；分值由评委
F10 决赛文档（5）	本报告 + 技术说明书；决赛 ≤50 页深化稿另做	初赛稿已备，决赛稿未做
E7/F6 效率	4+4 规模点实测（含免责声明）	部分：缺复杂度、并发、优化对照
F11/F12 答辩演示	PPT ≤20 页 + 匿名检查方法；现场表现不由仓库决定	未兑现（需现场）
加分申报	自述成稿 + 消融数据 + 诚实边界	默认 0；是否申报由复核结论决定