DataMind Agent 技术实现说明书

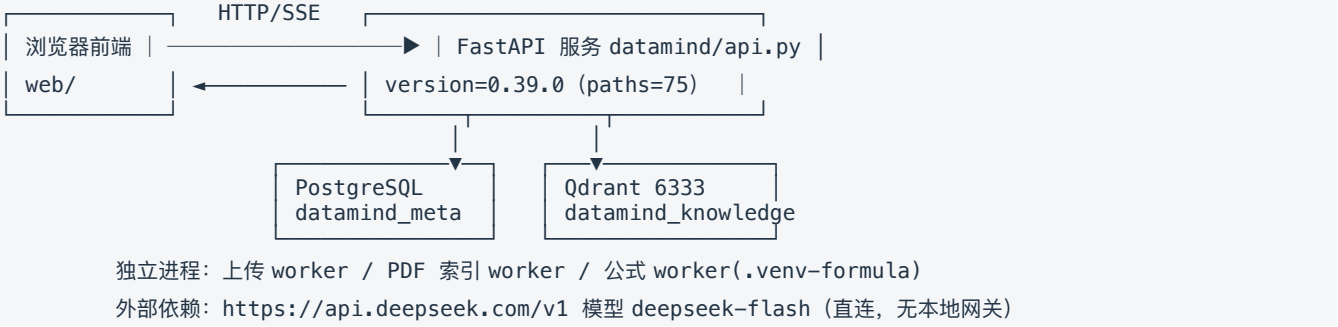
多模态数据驱动的可解释精准问数问答智能体

基线提交 e4e2ebf · API 0.39.0 · 覆盖范围：架构 / NL2SQL / RAG / 多源融合 / 可解释性 / 中级任务 / 测试与评估

阅读约定：文中每个数字后标注来源文件（相对仓库根目录）；数字分三类——①只读实测（/health、/openapi.json、只读 SQL）；②既有报告原值（reports/*.json）；③官方评分表原文（赛题 PDF 第 10–14 页）。三类不混用，需现场判定的一律写「无法判定」。

1. 系统架构

1.1 部署形态与进程



Mermaid（用代码块描述，Word 内不渲染）：

```
flowchart LR
  U[User] --> API[FastAPI api.py]
  API --> AG[agent.py route_for]
  AG -->|sql| SQ[sql_engine+sql_guard]
  AG -->|rag| RG[rag_engine+knowledge]
  AG -->|cross_source| UN[ROUTE_UNSUPPORTED]
  SQ --> PG[(PostgreSQL datamind_meta)]
  RG --> QD[(Qdrant)]
  SQ --> EV[(runs/events/evidence)]
  RG --> EV
  EV --> API
```

1.2 分层职责（与代码路径一一对应）

层	职责	路径
接口	REST + SSE；问答/回放/文档/上传/复核/权威/CAD/尺寸/私有 PDF	datamind/api.py
编排	路由 sql|rag|cross_source|工业；澄清；多轮 history 边界	datamind/agent.py
问数	问题帧 → Catalog 召回 → 模型 SQL → AST 门禁 → 只读执行 → 一次修复	sql_engine.py, catalog.py, sql_guard.py
问答	混合检索（向量+词法 RRF）→ 生成 → 片段/数字校验 → 拒答	knowledge.py, rag_engine.py
解析	统一解析契约（parse_status 五态、七类 locator、块/关系约束）	parse_contract.py, ingestion/*

治理	任务预算与进程组隔离、来源权威、字段复核、可见性、租约	task_budget.py, authority.py, visibility.py
存储	18 个迁移 001–018；元数据库 + 契约存储 + 证据图 + 任务/租约表	db/migrations/, deploy/init/

1.3 运行实例（只读实测，2026-10-09）

指标	值	命令
/health	status=ok, database=ready, knowledge=ready, vector_store=ready	curl http://127.0.0.1:8000/health
document_count	27	同上（另有 parsed 未索引 2 份，仅 SQL 可见）
chunks / facts / vectors	169 / 23 / 169	只读 SQL + GET /collections/datamind_knowledge
evidence_nodes / edges	1456 / 1359	只读 SQL
evaluation_cases	nl2sql=14、rag=12、robustness=4	只读 SQL（按 suite 分组）
API 路径数 / 版本	75 / 0.39.0	GET /openapi.json

2. 统一解析契约与多模态接入

整个系统的地基是「解析结果必须自证」：任何适配器产出的块与定位都要通过契约校验才能入库，缺口必须显式声明而不是留空。

2.1 契约要素

要素	内容	代码/证据
parse_status 五态	parsed / partial / failed / skipped / unsupported 语义化状态机	datamind/parse_contract.py
七类 SourceLocator	pdf_region、office_object、cad_entity、sheet_range、formula_region 等	同上（各自有必填字段与校验）
块与关系约束	block_id 定长摘要；relation 需 evidence 非空、禁止自引用；写库前再次校验	db/migrations/014–017
适配器登记与路由	按媒体签名探测 → dispatch 到已登记 handler；未登记报 PARSE_ADAPTER_UNKNOWN	ingestion/（PDF/Office/DXF/OHR JSON）
定位写入	document_block_locators 存 11 条真实 PDF 定位（实机验证）	PROGRESS.md 0.37.0「运行验收」

2.2 各模态的接入现状与缺口

模态	现状	缺口（如实）
原生 PDF	按 SHA 固定源、版本化块/切片、旋转/裁剪坐标保守处理	不发布到知识库；非 cgroup 硬隔离
扫描 PDF	原像素 OCR；块与 detail 与进程内路径关键字段一致（16 块/27 行/1.79s 实测）	表头 5/9、字段 3/15；清晰度评分与繁简纠错未做
DOCX/PPTX/XLSX	DOCX 标题/段落/整表、PPTX 文本框、XLSX 按行（真实行号）映射进契约	未解析样式/批注/修订/图表/备注/公式/合并单元格；Office 块未接入检索
DXF	dxf-native-v2：ARC/LWPOLYLINE/POLYLINE/INSERT 块展开/MTEXT/DIMENSION；部分成功 + 逐项声明	DWG/DGN 需外部转换器（明确拒绝）；无真实工厂泛化成绩
公式	隔离 Python 3.12 worker + ONNX 模型 + SHA256 校验 + LaTeX 结构校验	无公式求值引擎（官方 6b 未实现）
JSON 语料	OHR-Bench 走同一契约路径并声明 locator_unavailable	无页面定位

2.3 解析契约的 Mermaid 状态图（代码块描述）

```
stateDiagram-v2
  [*] --> parsed: 全部块通过 locator 校验
  parsed --> partial: 超上限/部分类型不支持
  parsed --> failed: 校验失败(PARSE_LOCATOR_INVALID)
  parsed --> skipped: 无块
  [*] --> unsupported: 适配器缺失/媒体不支持
```

```
partial --> indexed: 摄取成功且 chunks>0
failed --> [*]: 不中断摄取，如实记录
```

3. NL2SQL 实现

3.1 处理链路（含每步的失败码）

```
① query_frame：实体/指标/时间/数据库范围 → 缺项则 NEEDS_CLARIFICATION
② Catalog.retrieve(question, limit=8)：词法 + 中文别名 + 枚举 + Join Graph
③ 模型生成 SQL（提示词含 schema 快照与注册表口径）
④ sql_guard：sqlglot AST 解析 → 按 scope 解析列权限（RESTRICTED_COLUMN / SCHEMA_NOT_ALLOWED）
            → 指标口径结构比对（顶层投影必须是批准指标；禁止 OR；时间谓词必须在主 WHERE）
            → 参数绑定（文本序哨兵，保证占位符↔值映射正确）
⑤ 只读执行（DATAMIND 只读角色；无写入路径）
⑥ 失败分类 → 最多一次受控修复 → 返回 sql/rows/evidence
```

3.2 关键防线（来自独立复查后的修复）

缺陷类	曾出现的反例	当前处置	证据
CTE 同名绕过	public.customers 与某 CTE 同名 → 当作 CTE 跳过列检查	按作用域来源对象判定 is_cte 且无 schema 限定	PROGRESS.md 第 1 批 R01
指标篡改	正确 SUM 再乘 0 / 加常量 / 挪进无关子查询 / WHERE 追加 OR TRUE	顶层投影必须是批准指标，仅允许 Alias/ROUND/COALESCE/ABS/CAST 包装；禁 OR	PROGRESS.md 第 1 批 R02
连接粒度	多对多 JOIN 导致指标口径放大	按 catalog 外键方向判 METRIC_JOIN_GRAIN_RISK	同上
参数错配	sqlglot find_all(Placeholder) 顺序 ≠ 文本顺序	改为文本序哨兵映射	同上
派生表越权	不可验证的派生表携带受限列	sql_guard 按 scope 拒绝	docs/AUDIT_FIXES.md F01

3.3 评测结果（分子/分母，均为自建集）

套件	通过/总数	其他数字	来源
nl2sql（零售，14 条）	14/14	cases=14	reports/nl2sql.json
robustness（4 条）	4/4	错别字/口语/越权/空结果各 1	reports/robustness.json
schema linking（18 条）	表 31/31、列 28/28、指标 4/4、路径 6/6	Top-5 微平均召回	reports/schema_linking.json
工业问数	8/8 开发题	模型前澄清 2/2	PROGRESS.md「工业模型问数」
工业跨源规则（合成）	13/13	model_used=false	reports/industrial_rules.json

边界：以上全部为自建/合成集，非官方测试集；E5/F4 的官方准确率档「无法判定」。题面一致性与 append-only 护栏见 reports/cards/wp1a_registry.md。

4. RAG 实现

4.1 检索与生成

```
检索：BGE 向量（Qdrant） + 词法检索 → RRF 融合 → 候选片段（受任务预算约束）
生成：只允许使用本次候选证据；提示词含防注入边界
校验：①原文连续片段必须逐字出现 ②答案中的数字必须出自引用片段或标题
      ③未知 chunk 拒绝 ④最多一次修复 ⑤生成后重查证据身份（变化→409）
拒答：不满足即 insufficient，不补写、不猜测
```

4.2 显式多文档问答的约束

· 范围必须显式给出 1–8 份无重复公开文件（scope.document_refs），版本/源/解析器精确绑定。

· 每份文件必须有相关片段，否则阻断；检索覆盖与实际引用覆盖在生成结束后重验。

· 0 切片文档：前端不出勾选框；服务端在选中时拒绝 DOCUMENT_SELECTION_NOT_SEARCHABLE；证据漂移（切片哈希失效）则如实报告证据不完整（MULTIFILE_EVIDENCE_INCOMPLETE）——两者是不同语义，刻意不合并。

· 线上实测：/v1/documents 27 项中 26 可检索、1 不可检索（doc-industrial-0ac6c55838c3，no_chunks）。

4.3 结果与缺口

指标	值	来源
通过 / 用例数	10/12	reports/rag.json
可答题目数	answerable_count=11	同上
recall@5 / MRR@10	1.0 / 0.9545454545454546	同上
未通过原因（2 例）	1 例上游错误；1 例缺表头/公式拒答	审计 §4、docs/OFFICIAL_REQUIREMENTS_MAPPING.md A3
忠实度三态标注	未做（E6 无法判定）	docs/SCORE_GAP_LEDGER.md E6

4.4 私有 PDF 链路（另一条独立链路）

· 私有快照登记：admin/CSRF/同源、当前头 CAS、固定版本原文件/页图/bundle；服务 27/27、HTTP 19/19（PROGRESS.md）。

· 私有知识发布：冻结向量计划、独立认证 Qdrant、实际点确认、token/lease 栅栏；全 worker 最多 2 个 running。

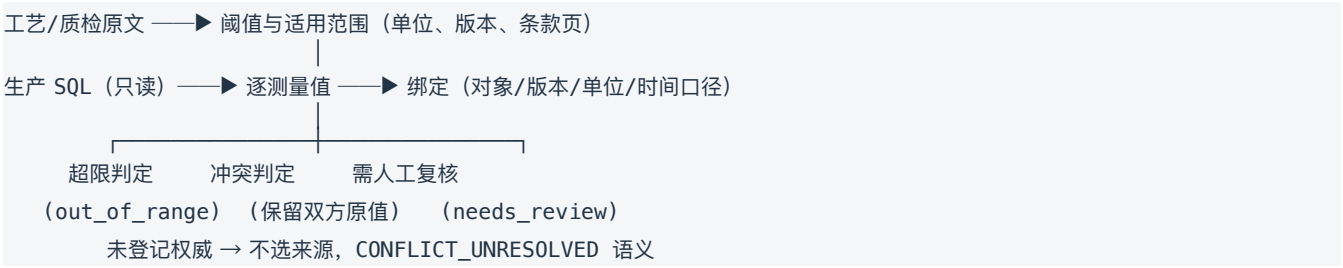
· 私有多文件检索：固定 publication/计划 SHA、1–4 份、同 embedding profile、逐文件覆盖；两个跨进程检索槽、总候选 512。

· 私有模型回答：只用本次选定片段、连续片段与数字校验、最多一次修复、文件未覆盖即拒答。

· 边界：不接公开知识、不写向量；真实模型忠实度与准确率未评测。

5. 多源融合与证据绑定

5.1 已实现：工业「原文 + 生产 SQL」逐测量核验



项	值	来源
规则冻结集通过	13/13	reports/industrial_rules.json
冲突 / 超限 / 待复核	conflicts=["M001-1"]； out_of_range=["M001-1","M006-2"]； needs_review 5 项	同上 runs[0].summary
是否调用模型	model_used=false	同上 runs[0].versions
保留的失败运行	run-49ac9fc9f84949f6（首轮序列化缺陷，保留不删）	同上 initial_implementation_failure_run

5.2 证据图存储现状

· 已有 evidence_nodes=1456 / evidence_edges=1359（只读 SQL），DDL 位于 deploy/init/02_metadata.sql:252-269。

· 现有边类型为 derived_from/retrieved_from/maps_to/supports/contradicts/verified_by/repaired_from；对照检查（entity_match/version_scope/unit_equivalent/time_overlap/conflicts）尚未建立。

· 绑定列 source_sha256/version/unit/time_scope 未建立；因此不能声称「版本化证据绑定已经落地」。

· 计划中的 019 迁移真实工作是「加绑定列 + 边类型 CHECK」，不是从零建表（docs/SCORE_GAP_LEDGER.md §3.3 P6/P7）。

5.3 通用跨源为何仍是 fail-closed

route_for() 只按关键词命中 cross_source，命中后直接返回 ROUTE_UNSUPPORTED。这是刻意的：在没有实体/版本/单位绑定与裁决门之前，猜测作答比拒答更危险。因此 F1 的「≥3 种结构不同的跨源问题」未达成，只能报已有工业链路的 13/13。

6. 可解释性与可追溯

6.1 证据出口清单

出口	内容	代码
答案载荷	sql、绑定参数、rows、citations（含 locators/relations）	datamind/agent.py、api.py
GET /v1/runs/{id}	运行摘要与状态	datamind/api.py
GET /v1/runs/{id}/evidence	证据集合（数据行 + 文档块 + 定位）	datamind/api.py
GET /v1/runs/{id}/events	事件流（可回放）	datamind/api.py
前端引用卡片	定位徽标/区域高亮；旋转页与非页面定位只显示标签	web/app.js
契约关系	read_relations 两向命中；只附存储中确有的	datamind/parse_contract.py

6.2 可视化纪律（防「猜测绘制」）

· 仅对未旋转的 pdf_region 提供区域高亮；rotation_degrees ≠ 0 时只显示标签。

· 非页面定位（office_object/cad_entity/sheet_range）不走区域绘制分支。

· 不从页码推导区域；查询定位失败不阻断回答，错误码独立记录。

· 有前端契约守护测试（node --check + 字段一致性 + 旋转拒绝分支存在性）。

· 边界：关系不参与排序/打分/重排/冲突消解；本轮未做界面视觉验收。

6.3 Mermaid（代码块描述）：一次跨源问答的时序

```
sequenceDiagram
  participant U as 用户
  participant A as agent
  participant S as sql_engine
  participant R as rag_engine
  participant E as 证据图
  U->>A: 跨源问题
  A->>S: 结构化子问题
  S-->>A: rows + sql
  A->>R: 文档子问题（绑定实体/版本）
  R-->>A: 片段 + 定位
  A->>E: 写入 nodes/edges
  E-->>A: 冲突?
  alt 冲突且无权威登记
    A-->>U: 双方证据 + 待裁决
  else 可判定
    A-->>U: 结论 + 完整证据链
  end
```

7. 中级任务实现细节

7.1 B3 语义校验与澄清

· clarify() 为规则式缺项检测（时间范围、口径、对象），产出 clarification 字段并按 NEEDS_CLARIFICATION 路由。

· 已实现的证据：工业套件「模型前澄清」2/2（reports/industrial_nl2sql.json）。

· 未达成：无完整「提出缺项 → 用户补充 → 消歧补槽 → 完成查询」闭环评测；无「不必要澄清率」指标；前端补槽交互未接入（docs/SCORE_GAP_LEDGER.md F2）。

7.2 B4 Schema Linking

```
Catalog.retrieve(question, limit=8)
  ├── 词法匹配（问题词 ↔ 表/列中文名与别名）
  ├── 别名映射（entity_aliases WHERE approved=TRUE，如 VIP→钻石）
  ├── 枚举值命中（列枚举与问题中的字面值）
  └── Join Graph 路径（Catalog.join_path，外键方向）
评测（reports/schema_linking.json）：表 31/31、语义锚点列 28/28、指标 4/4、路径 6/6
```

· 规模：18 条自建题、2 个 schema 快照（demo_retail、chinook），Top-5 微平均召回。

· 未达成：表数量未扩到 ≥40、未加入近义/命名相似干扰表、无未见问题集、错误路径拒绝率未单列。

7.3 B2 可扩展要素提取（机制就位，成本未测）

· 领域知识存于数据库注册表：schema_snapshots/_tables/_columns（中文名/别名/枚举/语义角色）、entity_aliases、business_metrics。

· db/build_catalog.py 由 introspection 生成，datamind/catalog.py 读取渲染 → 引擎不需要领域提示词。

· 未达成：未做「新增一个未参与开发的领域」的成本实验（配置行数、标注样本数、代码改动行数、旧领域回归影响），因此不主张「低成本扩展已被证明」。

7.4 B5 / B6 / B7 / B8 / B9 现状

难题	已实现部分	明确缺口
B5 多表 JOIN/聚合/嵌套	受控 JOIN + 语义门禁 + 粒度风险判定	样本小、无公开基准；嵌套与合法派生表覆盖不足
B6 公式识别与计算	ONNX 识别 + LaTeX 结构校验 + 块级 formula_latex 进引用	无求值引擎；6b 计算结果无实现
B7 混乱目录恢复	标题树优先切片、heading_level/reading_order 字段	无缺标题/错编号/伪标题/跨页层级专项集
B8 文档复杂度评估	—（映射表判「未实现」）	无复杂度评分模型或规则；仅有手工 difficulty 标签
B9 质量检测与告警	parse_status 五态、quality_findings、OCR 置信度、旋转校验	无清晰度评分、繁简/错别字校正、统一告警报告

8. 测试与评估体系

8.1 三层验证

层	规模与口径	入口
完整隔离回归	1297/1297，失败/错误 0，源库未修改（metadata_isolated=true）	scripts/test_isolated.py；reports/latest_regression.json
专项验证报告	按工作包分文件（契约/预算/PDF/OCR/消融/CAD 等）	reports/*_verification.json
冻结验收集	CAD 能力 31 例 365 断言；工业规则 13 例；schema 18 例	data/evaluation/、reports/cad_capability_v1.json

8.2 隔离回归的机制

· 克隆元数据库后执行；不复制模型设置、账户、会话、登录限流、权威规则、CAD 资产、私有 PDF 行。

· 报告 JSON 记录 metadata_isolated、source_database_modified 等布尔断言，便于机器核对。

· 纪律：新增测试会改变分母，每次同步 PROGRESS.md 的当前状态表（本轮未新增测试文件，分母未变）。

8.3 评测登记（append-only）

suite	登记文件	题数	digest（原文摘录，前 16 hex）
nl2sql	data/evaluation/registry/nl2sql_v1.json	14	a73bf740e4ad4eb9
rag	data/evaluation/registry/rag_v1.json	12	f5d42555a5831048
robustness	data/evaluation/registry/robustness_v1.json	4	ec105871014d2931

来源：reports/cards/wp1a_registry.md。check 实测 3/3 一致（exit 0）；重复冻结拒绝（exit 2）；篡改副本被检出（exit 1）；统一 schema 对三份历史报告报 0/3 符合（exit 1，如实结果）。

8.4 效率测量的口径（限制条件必须随数字一起引用）

· 机器：macOS-27.0.1-arm64，Apple M5 Pro，15 核，Python 3.14.5，内存 25,769,803,776 字节；每规模 3 次。

· 报告自带 4 条免责：单机单进程；无 CPU 绑定或 cgroup 隔离；无并发负载；非生产吞吐或容量承诺。

· CAD 5000/20000 实体档 parse_status=partial（blocks 上限 2000）→ 受限输出路径测量。

· 文档选择 1/2/5/8 份实际读取 9/14/34/44 行、耗时 102.9–107.3 ms，不可外推为「整套 RAG 只需 100 ms」。

9. 安全边界与工程治理

议题	实现	证据
跨源密钥不继承	跨源路径不带已存密钥；本机 sink 阳性对照实测 0 次外送	PROGRESS.md 0.38.0
网络暴露	仅绑定 127.0.0.1；免登录只读 socket 校验对端；同源固定白名单；中间件默认拒绝	docs/AUDIT_FIXES.md F03/F04
只读执行	SQL 侧无写入路径；评测登记连接 set_session(readonly=True)	datamind/sql_guard.py、data/evaluation/registry/registry.py
任务预算	跨进程资源槽、挂钟 deadline、进程组终止（含孙进程）、输出上限与稳定超时码	datamind/task_budget.py（34 项测试）
可见性统一判定	searchability(status,needs_review,chunks) 唯一入口，四个端点复用	PROGRESS.md 第 2 批 2a
依赖锁	requirements.lock 65 个固定版本 + 守护测试校验锁与实际安装一致	tests/test_dependency_lock.py
未知项不猜	未登记权威不选来源；未识别跨源问法返回稳定码；无切片的文档不可问答	industrial_rules.py、agent.py、upload_pipeline.searchability

9.1 已知未收敛项（原文照录，不修饰）

· F02 口径强制面仍窄（仅销售额别名族），复合指标按「无法独立校验」记录而不阻断。

· profile 解析仍有两套实现（行为已一致，实现未合并）。

· F10 摄取跨存储一致性仍有孤儿向量窗口（发布顺序协议已修，窗口未彻底关闭）。

· CPU/内存限额：RLIMIT_CPU 实测生效；RLIMIT_AS 在本机 macOS 被拒 → 内存上限失败关闭而非假装生效。

· 租约未接入执行路径；非 cgroup 硬隔离、非分布式共识。

9.2 仓库与交付治理

· git ls-files=605 个跟踪文件；db/migrations/*.sql=18；tests/ 目录 84 项（test_*.py 78 项，含 1 个 pending 目录项）。

· 交付物生成脚本独立放在 交付/_build/，不修改任何既有代码或文档。

· 交付清单（含 sha256 与生成命令）见 交付/DELIVERY_MANIFEST.json；官方提交物逐项状态见 docs/DELIVERY_CHECKLIST.md。

10. 已知局限与后续路线

10.1 局限（按官方评分项影响排序）

1. 通用跨源融合未建（F1）：当前仅工业结构跨源 13/13；无 ≥3 种结构差异的冻结集与绑定列。
2. 中级任务广度（F8/E8）：B3/B4 为「已实现（限定）」，B1/B2/B5/B6/B7/B9 为「部分」，B8 未实现。
3. 效率证明（E7/F6）：有 4+4 规模点实测，缺复杂度分析、并发吞吐与优化前后对照。
4. 多轮质量（E10）：契约与边界已实现并有 33 项测试，缺 ≥6 轮连续对话的准确率证据与前端接入。
5. 忠实度（E6）：只有组件级校验与端到端正确率，无逐结论三态标注。
6. 交付形态：决赛 ≤50 页深化稿与 ZIP 未打包（本轮明确不打 ZIP，只出清单与 dry-run 脚本）。

10.2 后续路线（与提升计划 WP 对应）

优先级	工作	验收判据
P0	跨源证据绑定 + 三种结构冻结集（WP2）	P1/P2/P3 ≥80%、错误绑定率 ≤5%、冲突 100% 展示双方
P0	同类绑定的对照消融（WP3）	三臂同集同环境；full 臂错误绑定率相对 plain 下降 ≥50% 且绝对 ≤5%
P1	交互式澄清闭环 + 不必要澄清率（WP4）	不必要澄清率 ≤10%；一次补充后完成查询
P1	效率证明补齐（WP8）	≥3 档 × 并发矩阵 + 复杂度 + 一处优化前后对照
P2	上传→索引→问答闭环（WP9）	≥10 份 ≥4 种格式；缺索引仍被拒绝

以上均为「完成并通过验收」的条件目标，不是已获分数，也不是官方成绩。

10.3 本说明书的诚实边界

· 本说明书未在干净空库环境重跑启动演练（本轮禁止重建容器/库），不主张「新环境已验证可启动」。

· 文中所有准确率/召回数字来自自建或合成集，官方测试集未提供；官方分档结论一律「无法判定」。

· V-CAR 消融为 16 例合成机制替身，不调用任何模型，不衡量 OCR/问答准确率，不能作为领先性证据。

· 本说明书不含任何单位名、合作方名或人名。