《突破与创新性自述》

版本化的跨源证据绑定 + 可控修复

DataMind Agent · 基线提交 e4e2ebf · API 0.39.0 · 篇幅 ≤5 页 · 第三轮（收口轮）同步版

1. 定位声明

跨源问数最危险的失败不是「查不到」，而是把证据绑错了对象、版本、单位或时间口径之后，仍然给出高置信度的答案。本项目不新增一个大模型，也不追求把模块数量堆满；我们把「绑定」从一个隐式假设提升为一等公民，并把它变成可度量、可复核、可在有限次数内受控修复的机制。

因此本项申报的方向是「实用创新与转化价值」而非「技术突破领先性」：我们没有与公开最优方案的对比实验，没有公开基准成绩，也没有真实视觉模型参与对比，不做任何「业界领先」的主张。若后续对照实验证明本机制相对普通流水线无差异，本项应降级为纯粹的工程化与可信性叙述。

对应官方加分方向（赛题 PDF 第 14 页原文要点）：「实用创新与转化价值 0~10 分 —— 提出了出奇简单、易于部署的解决方案；在工程化设计、系统架构、用户体验方面有突出贡献」。

2. 核心贡献（单一贡献，一句话可陈述）

系统不直接生成跨源结论，而是先生成一张带类型的证据图：数据行 / 文档块 / 测量 / 规范条款是节点；实体同一性、版本适用、单位等价、时间口径、数值支持、数值冲突是边。每条结论必须携带绑定字段（对象 + 版本 + 单位 + 时间口径 + 来源 sha256）；冲突在有限次数的受控修复内消解；无法消解时同时展示双方证据并标记待裁决，绝不自动单选一个来源。

2.1 机制要点与现有资产的对应（不是另起炉灶）

要素	已有资产（仓库路径）	本贡献的增量
实体同一性	entity_aliases（approved）参与 Schema 召回（datamind/catalog.py）	跨 SQL 行与文档块共用规范实体 id，绑定必须回指原值
连接路径	Catalog.join_path()（datamind/catalog.py）	多跳路径的跳数与证据边一起进入解释
版本与单位	图纸/工艺版本、industrial_rules.py 的单位与版本核验、来源权威登记（迁移 006）	泛化为 binding{entity_id, version, unit, time_scope, source_sha256} 并作为答案必填字段
冲突处理	工业规则「未登记权威时不选来源，保留双方原值」	升格为跨源通用裁决门 + 稳定错误码语义
受控修复	V-CAR 修复上限、ablation.py 的修复成功率/误修复率指标	只修绑定错误，每次修复记账，设误修复率硬门
可解释	事件流、回放、引用卡片、契约关系	证据图可视化：节点类型、边类型、绑定字段、冲突双方

2.2 可复现度量（本贡献真正缺过的东西）

1. 绑定准确率 = 正确绑定到（对象 + 版本 + 单位 + 时间口径）的声称 / 全部答案声称。
2. 错误绑定率（标志性指标）= 绑定错误却仍以高置信度输出的声称比例；零分母报 N/A，不用 0 冒充。
3. 冲突检出率 / 误报率：同一来源相反值、跨版本不一致、单位不可归一化、时间范围不重叠，四类分别报 P/R。

4. 修复账本：尝试次数、成功率、误修复率、每次修复带来的延迟与 token 成本。

5. 对照消融：plain（直接拼接 SQL 结果与文档片段作答）/ bind_only（绑定但不核验）/ full（绑定 + 核验 + 受控修复）三臂在同一冻结集同一环境比较。

3. 举证（只用仓库内真实存在、且可被复核的数字）

3.1 证据状态总览（逐份点名，只读实测；核对时刻 2026-10-10T08:35+08:00）

被引用文件	只读实测状态	记录/规模	独立复核判定
reports/cross_source_offline.json	**存在**（13 798 B）	21 用例 / 161 断言 / model_calls=0	confirmed（C01–C10；第三轮复跑逐例 verdict 差异 0）
reports/binding_ablation.json	**存在**（219 605 B，sha256 前 16 位 d086dd2e24014965，generated_at 2026-10-09T15:36:52+00:00）	40 例陷阱 / 3 臂 / 68 条 arm-case 失败 / model_calls=0	**冻结集与门槛算术已独立复跑**（`--check` exit 0、problems []、pin_matches true）
reports/cross_source_live.json	**存在**	P1 5/6；model_calls=17；checks 55/60	内部一致；**未经独立重跑**（需真实模型）
reports/cross_source_norm_live.json	**存在**	P2/P3/P4 28/28；**model_calls=0**；文档侧为自建语料	管线**已独立复现**（逐例 answer 零差异）；非模型成绩
reports/vcar_ablation.json	**存在**	16 例合成机制消融	confirmed（C132：dataset/sha256/cases/generated_at 逐字段一致）
data/evaluation/binding_traps_v1.json	**存在**	40 例（四类各 10）	第三轮 `--check` exit 0，摘要 1fdfa89b…

3.2 跨源离线证据（reports/cross_source_offline.json）

该报告为**注入 fixture + 期望先冻结**的内部一致性评测（`model_calls = 0`），不是泛化准确率，也不衡量真实模型：21/21 用例、161/161 断言通过；其中 6 条为设计内 fail-closed（4 条 `DOC_BINDING_MISSING` + 2 条 `CONFLICT_UNRESOLVED`）。第三轮复核者独立复跑得同一结果，逐例 verdict 差异 0。

指标	分子/分母	值	来源
用例通过率（注入 fixture）	21/21	1.0	cross_source_offline.json totals
断言通过率（内部一致性）	161/161	1.0	cross_source_offline.json checks
设计内 fail-closed 保留	6/21	0.2857	error_code_counts + cases[]
模型调用次数	0	0	model_calls

结构性瑕疵（如实保留）：该报告与 `cross_source_norm_live.json` 的机器可读 `failure_samples` 均为空数组/未含全部非完成例，失败清单需从 `cases[]` 与 `error_code_counts` 逐条取（review_round1_evidence §5 与第三轮复核 §3.4 均已记录）。

3.3 绑定三臂消融（reports/binding_ablation.json；硬判定满足申报门槛）

该报告在 40 例冻结绑定陷阱集（同对象跨版本 / 单位不可归一 / 时间口径不同 / 文档与库数值相反，各 10 例）上跑 `plain` / `bind_only` / `full` 三臂，作答器为确定性桩（`answerer = deterministic-stub`，`model_calls = 0`）。**硬判定**原文：`criterion = full 臂错误绑定率相对 plain 臂下降 ≥50% 且绝对值 ≤5%`，`plain_misbinding_rate = 0.8`、`full_misbinding_rate = 0.0`、`relative_drop = 1.0`、`meets = true`。

臂	绑定准确率	错误绑定率（high 声	错误绑定率（全例口	冲突 P/R	误修复率

		称口径）	径）		
plain	8/40 = 0.200	32/40 = 0.800	32/40 = 0.800	N/A / 0/25	N/A（无改写）
bind_only	8/40 = 0.200	27/35 = 0.7714	27/40 = 0.675	N/A / 0/25	N/A（无改写）
full	40/40 = 1.000	**0/17 = 0.000**	**0/40 = 0.000**	**25/25 / 25/25**	**0/9 = 0.000**

full 臂修复账本：attempts 15 / changed 9 / rejected 6 / succeeded 9 / misrepair 0（成功率 1.0、误修复率 0/9）；high 断言 17/40，另 23 例按设计拒答；`failures[]` 保留 **68 条** arm-case 失败（plain 34、bind_only 34、full 0）。敏感性探针：拆掉版本核验/冲突门/修复后，错误绑定率回到 0.500（9/18）/ 0.541（20/37）、绑定准确率 0.800。

独立复核状态（第三轮）：`scripts/eval_binding.py --check` 已由独立复核者复跑 → **exit 0**、**`problems: []`**、**`pin_matches: true`**、**40 例**，冻结集与门槛算术**已被确认**；但作答器仍是**确定性桩**、陷阱集仍是**自建**，故这些数字**不是模型准确率**，不得主张业界领先。

3.4 跨源规范语料证据：P2 / P3 / P4（reports/cross_source_norm_live.json）

第三轮新增 14 份自建规范文档（`data/knowledge_sources/`，5 PDF + 9 DOCX，30 条条款），把「文档规则驱动 SQL 筛选」（P2）、「跨源冲突核验」（P3）、「复杂多跳」（P4）做成在**真实演示库 + 真实文件解析**上可复算的证据：28/28 通过，P2 12/12、P3 5/5、P4 6/6 `answered_and_verified`。**但 `model_calls = 0`**：SQL 由条款确定性编译，**不是 NL2SQL，也没有模型参与**；文档侧是**本轮自建语料**。第三轮已独立复跑该命令（exit 0），逐例 `answer` 文本差异 **0**。

结构	真实成功（answered_and_verified）	分母	是否有模型	文档侧来源
P1 SQL 结果驱动文档检索	**5**（cross_source_live.json）	6	**是**（model_calls 17）	公开知识库 169 条切片
P2 文档规则驱动 SQL 筛选	**12**	12	否（model_calls 0）	自建语料 14 份
P3 跨源冲突核验	**5**	5	否	自建语料 14 份
P4 复杂多跳	**6**	6	否	自建语料 14 份

F1 档位判断（不抬档）：官方 F1「能正确回答至少 3 种跨源问题得 6 分」。当前 4 种结构里只有 P1 有**真实模型**端到端记录（单次 5/6），P2/P3/P4 的 23 条答案 `model_calls = 0` 且文档侧为自建语料；另有 3 处引擎判定缺陷已被本轮冻结（`edge_between` 单向键查找导致 P4 引擎 2/9 vs 独立重算 9/9、条款无「适用对象」门控、冲突键不含测量标识产生假冲突）。因此**本自述不主张 F1 已计入 6 分档**；可诚实陈述的是：跨源证据从「完全缺失」推进到「4 种结构、28 条可复现记录，其中 1 种有真实模型记录」。

3.5 仍未产出、因此不作主张的证据

- 公开基准对比（Spider/BIRD 等）与真实视觉模型对比：**未产出**，不作主张。
- 跨源 P2/P3/P4 的**真实模型**端到端（NL2SQL + 生成）：**未产出**，不作主张。
- 逐页人工视觉检查与干净环境演练：**未做**，不作主张。

3.6 报告自带的边界（原文照录，必须与数字同时引用）

```
binding_ablation.json boundaries（原文照录）：
  · stub 作答器：不调用任何上游模型（model_calls=0），不是真实模型准确率，也不能外推为业务准确率；
  · 自建冻结陷阱集：40 例由本仓库自行编写并冻结，plain 臂的失败来自陷阱的设计，
    「相对下降」是机制对照结果，不是泛化能力的证明；
  · 零分母一律 N/A（None），不用 0 冒充；分母分子报告在同一条目内；
  · failures[] 保留每一条失败样本（含 plain/bind_only/full 三臂），未做任何剔除；
  · 本报告不衡量真实模型、真实演示库查询或前端表现。
```

```
claim_boundary（原文照录）：full 臂通过门槛只能支持「在冻结定义下机制有效」的实用创新举证；
  若要主张技术突破领先性，还需要真实模型 + 独立外部数据的证据。
```

4. 诚实边界（不主张什么）

1. **无真实视觉模型对比**：上游仅文本模型，仓库无本地视觉权重目录（docs/MODEL_WEIGHTS.md）；`vcar_ablation.json` 的 local 臂是机制替身，不得当作真实视觉模型成绩。

2. **不得主张业界领先**：无与公开最优方案的对比实验，无公开基准成绩；绑定三臂消融是**自建冻结集 + 确定性 stub** 上的机制对照，不是泛化能力，也不是业界领先。

3. **离线/stub 不等于模型准确率**：`cross_source_offline.json`、`binding_ablation.json` 与 `cross_source_norm_live.json`（其 `mode: live` 指真实库/真实文件，**不是真实模型**，`model_calls = 0`）均不得外推为业务准确率。

4. **绑定消融的独立复核范围有限**：第三轮只独立复跑确认了**冻结集与门槛算术**（`--check` exit 0）；`full` 臂 40/40 是陷阱集与机制同源设计的结果，不构成泛化证据。

5. **不主张通用跨源已实现**：第一轮安全复查的 H1/M1/M2/M4/L2/L3/L5 已在第二轮修复、L4（生产路径耦合评测脚本）已在第三轮下沉到 `datamind/clarification.py`；但跨源真实链路**只跑通 P1 一种结构**（5/6），P2/P3/P4 的真实模型端到端仍未产出。

6. **不主张任何官方得分**：官方测试集未提供；本项目全部数字来自自建或合成冻结集。

7. **不主张「plain 臂一定更差」的普适结论**：本冻结集上 plain 错误绑定率 0.800，但该值由陷阱设计决定；若在独立外部数据上 plain 接近满分，本项只能申报转化与工程价值。

8. **不主张「版本化证据绑定已全库落地」**：既有 `evidence_nodes`/`evidence_edges` 表结构见 docs/SCORE_GAP_LEDGER.md §3.3，绑定字段的库级落地范围以该文件为准，本自述不扩大。

5. 评审价值与可复核入口

· 对评委：本贡献把「可解释」从界面展示推进到可度量的绑定正确性；评委可用同一冻结集复跑三臂对照，并逐条阅读 68 条失败样本与敏感性探针。

· 对工程：绑定字段与证据图是通用抽象，不依赖某个领域提示词；新增领域只需要登记元数据（已有 schema 注册表机制）。

· 对产品：冲突「同时展示双方 + 待裁决」比自动选一个来源更贴近真实业务责任边界（谁有权裁定由人决定）。

· 可复核入口：reports/binding_ablation.json、reports/cross_source_offline.json、reports/cross_source_live.json、reports/cross_source_norm_live.json、reports/review_round3_final.md、reports/cards/wp3_binding.md、reports/cards/r3_cross_source_norm.md、docs/SCORE_GAP_LEDGER.md §5。

5.1 本自述的复现命令（全部只读 / 不写演示库）

```
cd "/Users/caicai/DataMind Agent"
git rev-parse --short HEAD                                    # e4e2ebf（只读）
.venv/bin/python scripts/eval_binding.py --check; echo "exit=$?"        # 0 → problems: []
.venv/bin/python scripts/eval_cross_source_norm.py --check; echo "exit=$?"  # 0 → 28 例标签复算
.venv/bin/python -c "import json;d=json.load(open('reports/binding_ablation.json'));print(d['verdict'])"
#   → {'meets': True, 'relative_drop': 1.0, 'plain_misbinding_rate': 0.8, 'full_misbinding_rate': 0.0}
.venv/bin/python -c "import json;d=json.load(open('reports/cross_source_live.json'));print(d['live_summary'],
d['model_calls'])"
#   → P1 5/6 answered_and_verified; model_calls 17
```

本自述与设计报告、技术说明书、答辩演示同步交付；所有数字均可由上述命令与报告文件复核。